

Домашнее задание № 16

1. Разворачиваем AirFlow

- o Создаем директорию airflow-project для Airflow и переходим в нее
- o Скачиваем официальный файл docker-compose.yml

```
curl -Lfo 'https://airflow.apache.org/docs/apache-airflow/stable/docker-compose.yaml'
```

- o Создаем необходимые папки

```
mkdir -p ./dags ./logs ./plugins ./config
```

- o Создаем файл .env

```
# Генерируем FERNET_KEY
FERNET_KEY=$(python3 -c "from cryptography.fernet import Fernet; print(Fernet.generate_key().decode())" 2>/dev/null || openssl rand -base64 32)

# Создаём .env
cat > .env <<EOF
AIRFLOW_UID=$(id -u)
FERNET_KEY=${FERNET_KEY}
_AIRFLOW_WWW_USER_USERNAME=airflow
_AIRFLOW_WWW_USER_PASSWORD=airflow
EOF
```

- o Добавляем сети
В секцию x-airflow-common

```
networks:
  - default
  - clickhouse-network
```

В конце файла

```
networks:
  default:
    name: airflow_default
  clickhouse-network:
    external: true
    name: <ИМЯ_СЕТИ_CLICKHOUSE>
```

- o Выполняем инициализацию и запуск:


```
# 1. Инициализация БД и создание пользователя
docker compose up airflow-init

# 2. Запуск всех сервисов
docker compose up -d

# 3. Проверка статуса
docker compose ps
```

- Открываем веб-интерфейс: `http://localhost:8080`, логин/пароль — `airflow / airflow`

Добро пожаловать



- Проверяем связь с ClickHouse

```
$ docker compose exec airflow-scheduler ping -c 2 clickhouse-replica-1
PING clickhouse-replica-1 (172.19.0.3) 56(84) bytes of data.
64 bytes from clickhouse-replica-1.clickhouse-docker_clickhouse-network (172.19.0.3): icmp_seq=1 ttl=64 time=1.75 ms
64 bytes from clickhouse-replica-1.clickhouse-docker_clickhouse-network (172.19.0.3): icmp_seq=2 ttl=64 time=0.041 ms

--- clickhouse-replica-1 ping statistics ---
2 packets transmitted, 2 received, 0% packet loss, time 1001ms
rtt min/avg/max/mdev = 0.041/0.894/1.747/0.853 ms
```

2. Настраиваем подключение к ClickHouse

- Устанавливаем провайдер ClickHouse

Создаем файл `Dockerfile`

```
dockerfile

FROM apache/airflow:3.3.2

# Устанавливаем провайдер от имени пользователя airflow
RUN pip install --no-cache-dir apache-airflow-providers-clickhousedb
```

В `docker-compose.yml` в секции `x-airflow-common` комментируем строку `image:` и раскомментируем `build:`:

```
x-airflow-common:
  &airflow-common
  # image: ${AIRFLOW_IMAGE_NAME:-apache/airflow:3.3.2}
  build: .
  # ... остальные настройки ...
```

Пересобираем образ и запускаем Airflow

```
docker compose build
docker compose down
docker compose up -d
```

о Создаем подключение в AirFlow

Редактировать соединение

ID соединения *

clickhouse_default

Тип соединения *

ClickHouse

Отсутствует тип соединения? Убедитесь, что вы установили соответствующий пакет Airflow Providers.

Стандартные поля

Описание

Хост

clickhouse-replica-1

Логин

default

Пароль

...

Порт

8123

Database

default

3. Создаем DAG для загрузки данных

Создаем файл `nyc_taxi_to_clickhouse.py` в папке `./dags/`

```
from datetime import datetime
```

```
from airflow import DAG
from airflow.providers.common.sql.operators.sql import SQLExecuteQueryOperator
```

```
# Параметры
```

```
CLICKHOUSE_CONN_ID = "clickhouse_default"
```

```
TARGET_TABLE = "trips"
```

```
# URL с данными в S3 (из документации ClickHouse)
```

```
# Синтаксис {0..2} означает файлы trips_0.gz, trips_1.gz, trips_2.gz
```

```
S3_URL = "https://datasets-documentation.s3.eu-west-3.amazonaws.com/nyc-taxi/trips_{0..2}.gz"
```

```
with DAG(
```

```
    dag_id="nyc_taxi_etl",
```

```
    start_date=datetime(2024, 1, 1),
```

```
    schedule="@daily",
```

```
    catchup=False,
```

```
    tags=["example", "clickhouse"],
```

```
) as dag:
```

```
# Задача 1: Создать таблицу
```

```
create_table = SQLExecuteQueryOperator(
```

```
    task_id="create_table",
```

```
    conn_id=CLICKHOUSE_CONN_ID,
```

```
    sql=f"""
```

```
CREATE TABLE IF NOT EXISTS {TARGET_TABLE} (
```

```
    trip_id UInt32,
```

```
    pickup_datetime DateTime,
```

```
    dropoff_datetime DateTime,
```

```
    pickup_longitude Nullable(Float64),
```

```
    pickup_latitude Nullable(Float64),
```

```
    dropoff_longitude Nullable(Float64),
```

```
    dropoff_latitude Nullable(Float64),
```

```
    passenger_count UInt8,
```

```
    trip_distance Float32,
```

```
    fare_amount Float32,
```

```
    extra Float32,
```

```
    tip_amount Float32,
```

```
    tolls amount Float32,
```

```
    total_amount Float32,
```

```
    payment_type Enum('CSH' = 1, 'CRE' = 2, 'NOC' = 3, 'DIS' = 4, 'UNK' = 5),
```

```
    pickup_ntaname LowCardinality(String),
```

```
    dropoff_ntaname LowCardinality(String)
```

```
) ENGINE = MergeTree()
```

```
PRIMARY KEY (pickup_datetime, dropoff_datetime);
```

```
""",
```

```
)
```

```
# Задача 2: Загрузить данные из S3 напрямую в ClickHouse
```

```
load_data = SQLExecuteQueryOperator(
```

```
    task_id="load_data",
```

```
    conn_id=CLICKHOUSE_CONN_ID,
```

```
    sql=f"""
```

```
INSERT INTO {TARGET_TABLE}
```

```
SELECT
```

```
    trip_id,
```

```
    pickup_datetime,
```

```
    dropoff_datetime,
```

```
    pickup_longitude,
```

```
    pickup_latitude,
```

```
    dropoff_longitude,
```

```
    dropoff_latitude,
```

```
    passenger_count,
```

```
    trip_distance,
```

```
    fare_amount,
```

```
    extra,
```

```
    tip_amount,
```

```
    tolls_amount,
```

```
    total_amount,
```

```
    payment_type,
```

```
    pickup_ntaname,
```

```
    dropoff_ntaname
```

```
FROM s3(
```

```
    '{S3_URL}',
```

```
    'TabSeparatedWithNames'
```

```
);
```

```
""",
```

```
)
```

```
create_table >> load_data|
```

4. Запуск и проверка

Dag-иЗапуски Dag-aЭкземпляры задачи

Поиск Dag-ов (Ctrl+ K)

Последний запуск: Все состоянияЛюбой запуск: Все состоянияНеобходимые действияВсеАктивныеПриостановленныеФильтр по тегу

ВсеИзбранныеНе избранные

1 DagСортировать по имени (A-Z)

nyc_taxi_etl clickhouse, example

Расписание: 00***Последний запуск: Следующий запуск: 2026-10-05 03:00:00

Dag-иЗапуски Dag-aЭкземпляры задачи

Поиск Dag-ов (Ctrl+ K)

Последний запуск: Все состоянияЛюбой запуск: Все состоянияНеобходимые действияВсеАктивныеПриостановленныеФильтр по тегу

ВсеИзбранныеНе избранные

1 DagСортировать по имени (A-Z)

nyc_taxi_etl clickhouse, example

Расписание: 00***Последний запуск: 2026-10-06 01:20:36 Следующий запуск: 2026-10-06 03:00:00

-- проверка результата
SELECT count() FROM trips;

trips 1

SELECT count() FROM trips

123 count()

13 000 317